基于卷积网络的图像分类实验报告

1 实验设置与总体流程

实验全部在自建的统一训练框架中完成。原版的 `resnet-cifar100.py` 与 `config.yml` 没有改动。为便于比较，除专门考察的变量外，各项实验都固定 seed=42、开启 AMP 混合精度，CIFAR-100 用 batch=256，交通标志用 batch=64，SGD 的 momentum 与 weight decay 分别取 0.9 与 10^{-4}。每组实验逐 epoch 记录训练损失、测试精度、耗时与学习率，写入 `results/*.csv`，同时保存最佳权重，图表与本文的数据都直接读自这些文件。环境信息见表 1。

表 1　实验环境与统一设置

项目	配置
数据集	CIFAR-100：100 类，50000 训练 / 10000 测试，32×32； 交通标志：10 类，6024 训练 / 324 测试，原始 224×224（训练时缩放）
软件环境	Python 3.12、PyTorch 2.11.0+cu128、torchvision 0.26.0、CUDA 12.8
硬件	NVIDIA RTX 4070 Laptop（8 GB）
统一设置	seed=42；AMP 混合精度；CIFAR batch=256、交通标志 batch=64； SGD momentum=0.9、weight decay=10^{-4}（另做 Adam/AdamW/RMSprop 对比）

2 任务 1：跑通 ResNet10 + CIFAR-100 基线

2.1 完成过程

装好 `requirements.txt` 中的 PyTorch、torchvision 与 ignite，确认 CUDA 可用后，直接运行 `resnet-cifar100.py`（`config.yml`：SGD、lr=0.001、batch=256、50 epoch），完整训练 50 个 epoch，最佳精度 37.21%，总耗时 13.1 min。原版脚本与配置文件都没有改动。

表 2　原版脚本的运行结果

脚本	优化器 / lr	epoch	最佳精度 (%)	耗时 (min)
`resnet-cifar100.py`	SGD / 0.001	50	**37.21**	13.1

2.2 结果分析

37.21% 说明网络、数据加载与训练流程可以正常完成一轮完整训练。日志中训练损失到第 50 epoch 仍有 2.34，末轮精度低于中途的最好值，对应 `config.yml` 中的学习率 0.001：该学习率下 SGD 在 50 epoch 内尚未收敛。

3 任务 2：优化器对比（SGD / Adam / AdamW / RMSprop）

3.1 完成过程

固定 ResNet10、batch=256、50 epoch 与恒定学习率，只替换优化器，分别用 SGD(lr=0.1)、Adam(10^{-3})、AdamW(10^{-3})、RMSprop(10^{-3})，动量与权重衰减保持一致，结果见表 3 与图 1。

表 3　四种优化器对比（ResNet10、CIFAR-100、恒定 lr、50 epoch）

优化器	lr	最佳精度 (%)	末轮精度 (%)	耗时 (min)
SGD (momentum=0.9)	0.1	66.44	64.85	6.5
Adam	0.001	66.16	65.28	6.5
AdamW	0.001	**66.70**	66.29	6.5
RMSprop (momentum=0.9)	0.001	51.70	48.27	6.6

3.2 结果分析

前 20 个 epoch 中 Adam 与 AdamW 的精度上升最快，Adam 第 20 epoch 为 62.60%，SGD 同期约 62%，二十个 epoch 之后三条曲线基本重合。最终 AdamW 66.70%、SGD 66.44%、Adam 66.16%，最大差距 0.54 点；在学习率各自合适的情况下，三者最终精度差别有限。AdamW 略高，但需要额外调参，实验中 SGD 加动量已能得到接近的结果。

RMSprop 为 51.70%，训练损失在后期停在 1.46 左右不再下降，测试精度在 44%～52% 之间波动，属于 lr=10^{-3} 下 50 epoch 未收敛的情形；受实验时间限制，未再调整其学习率。

作为对照，同为 SGD 只把恒定 lr 换成 step 衰减，精度从 66.44% 升到 71.38%，提高 4.94 点，大于更换优化器带来的差距。

4 任务 3：学习率影响与动态调节

4.1 完成过程

先在 SGD 下做固定学习率扫描，取 lr = 0.001 / 0.01 / 0.1 / 0.3，其余设置完全相同，各训练 50 epoch，其中 lr=0.001 就是任务 1 原版脚本的配置，0.1 与任务 2 的 SGD 组是同一次训练，结果见表 4 与图 2。随后做动态调

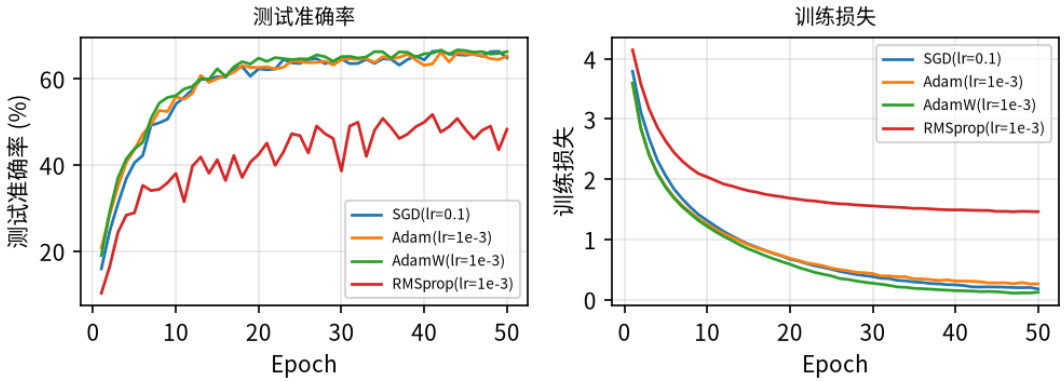


图 1　四种优化器的测试准确率与训练损失（ResNet10，CIFAR-100，50 epoch，恒定 lr）

节：以 0.1 为初值，在第 30、40 epoch 各降 10 倍（0.1 → 0.01 → 0.001），记录训练损失随 epoch 的曲线和对应精度，见图 3。

表 4　不同恒定学习率下的精度对比（SGD、ResNet10、50 epoch）

SGD 学习率（恒定）	0.001	0.01	0.1	0.3
最佳精度 (%)	36.86	63.60	**66.44**	63.47
末轮精度 (%)	36.16	61.61	64.85	61.22

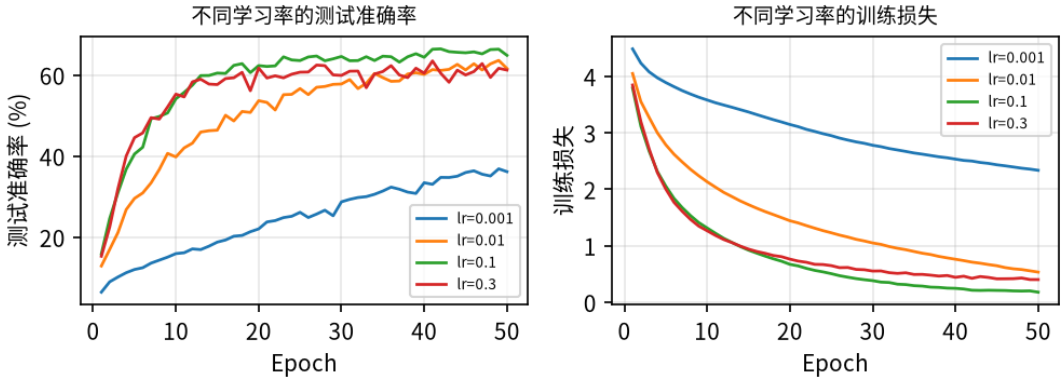


图 2　不同学习率下的测试准确率与训练损失（SGD，ResNet10，恒定 lr，50 epoch）

4.2　结果分析

精度随学习率呈 U 形变化。lr=0.001 时只有 36.9%，训练损失 2.34 且到末轮仍在下降，属于欠拟合；0.01 为 63.6%；0.1 最高，66.4%；0.3 回落到 63.5%。lr=0.3 的末轮训练损失 0.400 高于 0.1 的 0.177，测试精度在后 20 epoch 于 58%～63% 之间波动，对应步长过大时在极小值附近震荡的情形。

第 30 到 31 epoch 学习率由 0.1 降到 0.01，精度由 65.40% 升到 70.73%，提高 5.33 点；第 40 epoch 再降一次后趋于稳定，最佳 71.38% 出现在第 45 epoch，比恒定 0.1 高 4.94 点。训练损失呈台阶式下降：第 30 epoch 末约 0.38，降 lr 后为 0.21，第 40 epoch 末 0.09，最终 0.080，曲线波动很小。这与前面的扫描一致：前期需要较大步长，后期需要较小步长，一次训练中兼顾两者需借助调度。任务 6 因此改用余弦退火。

5　任务 4：网络改为 ResNet18 / ResNet50 并对比三种网络

5.1　完成过程

原版代码只能构造 ResNet10，这里把构造方式改成可以传入 block 类型与各 stage 层数，从而得到 ResNet18（BasicBlock，[2,2,2,2]）与 ResNet50（Bottleneck，[3,4,6,3]）。分类头维度按 512×expansion 自动计算，ResNet50 即为 2048。三种网络沿用同一套为 CIFAR 设计的 stem（3 × 3 卷积、去掉 maxpool、只下采样三次），训练配置也完全一致（SGD lr=0.1 加 step 衰减、50 epoch、batch=256、AMP），只改网络本身。ResNet50 训练中途因为显存和内存压力中断过一次，从最佳权重热启动补看了剩余 epoch，学习率按同样的调度恢复。三种网络的规模、耗时与精度见表 5 与图 4。

5.2　结果分析

精度没有随深度单调上升。ResNet10 为 71.38%，ResNet18 升到 72.73%（+1.35 点），ResNet50 降到 70.16%（−2.57 点）。训练开销随之增加：总耗时 6.5、12.6、45.1 min，ResNet50 参数量 23.7 M，是 ResNet18 的 2.1 倍，单 epoch 时间大约是它的 4.3 倍（0.22 对 0.96 min）。

ResNet50 的末轮训练损失为 0.105，高于 ResNet18 的 0.034，训练损失仍在下降区间，属于 50 epoch 预算内尚未收敛，而非过拟合。32×32 的输入下，参数量更大的模型优化更慢，短预算内难以体现容量优势。三项中 ResNet18 精度最高、耗时居中（72.73%，12.6 min），任务 5 因此选它作学生网络。

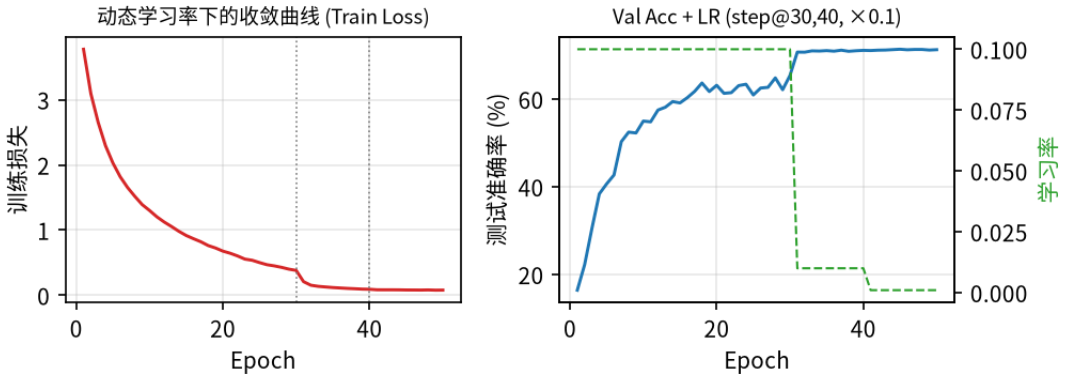


图 3　学习率动态衰减（第 30、40 epoch 各降 10 倍）下的训练损失与测试精度收敛曲线

表 5　ResNet10 / 18 / 50 的规模、耗时与精度（CIFAR-100）

网络	结构	参数量	总耗时 (min)	每 epoch (min)	最佳精度 (%)
ResNet10	BasicBlock [1,1,1,1]	4,949,412	6.5	0.12	71.38
ResNet18	BasicBlock [2,2,2,2]	11,220,132	12.6	0.22	**72.73**
ResNet50	Bottleneck [3,4,6,3]	23,705,252	45.1	0.96	70.16

6　任务 5：知识蒸馏（ResNet50 教师 → ResNet18 学生）

6.1　完成过程

教师直接用任务 4 训练好的 ResNet50 最佳权重（最佳精度 70.16%，第 42 epoch），推理模式下不更新参数。学生仍为 ResNet18，训练配置与任务 4 的无蒸馏基线完全一致，只把损失函数换掉，这样结果的差异只能归因于蒸馏。

两种损失都实现了。第一种是 Hinton 提出的 soft target，温度 $T = 4$、硬标签权重 $\alpha = 0.7$：

$$\mathcal{L}_{\text{soft}} = \alpha\,\mathcal{L}_{\text{CE}}(z_s, y) + (1-\alpha)\,T^2\,\text{KL}\big(\text{softmax}(z_t/T)\,\big\|\,\text{softmax}(z_s/T)\big)\,,$$

乘 T^2 是为了补回温度对梯度的缩放。第二种按 FitNets 的思路对齐 logits，$\alpha = 0.5$，soft target 项换成学生与教师 logits 的均方误差：

$$\mathcal{L}_{\text{logit}} = \alpha\,\mathcal{L}_{\text{CE}}(z_s, y) + (1-\alpha)\,\|z_s - z_t\|_2^2/N.$$

两组结果与无蒸馏基线一起列在表 6，曲线见图 5。

表 6　知识蒸馏结果（学生 ResNet18，CIFAR-100，50 epoch）

方法	教师	学生参数量	最佳精度 (%)	较学生基线
ResNet18 基准（无蒸馏）	—	11,220,132	72.73	—
KD soft target（T=4, α=0.7）	ResNet50	11,220,132	**73.46**	+0.73
KD logits（MSE, α=0.5）	ResNet50	11,220,132	71.97	−0.76
（参考）教师 ResNet50	—	23,705,252	70.16	—

6.2　结果分析

soft target 的学生精度为 73.46%，比无蒸馏基线高 0.73 点，且前期学得更快：第 10 epoch 已经 64.20%，基线同期只有 55.92%。这一组的训练损失里含有蒸馏项（第 1 epoch 就达到 7.2，约为 $0.3\,\mathcal{L}_{\text{CE}} + 0.7\,T^2\text{KL}$），与纯交叉熵的数值不可直接比较，因此以精度曲线作为判据。

logits 对齐为 71.97%，比基线低 0.76 点。该损失初期收敛很快，第 10 epoch 已达 66.39%，之后增速下降。可能的原因是 MSE 要求学生逐维贴合教师的 logit 数值，而 100 类分类中教师的 logit 尺度较大，该项会将学生拉向教师的数值范围，后期优化难度较大，稳定性不如带温度的 KL。

实验中教师精度为 70.16%，低于不蒸馏的学生基线，蒸馏后的学生比教师高 3.30 点。教师是在 50 epoch 预算内未充分收敛的 ResNet50，但其输出仍包含类与类之间的相似性信息，软标签为学生提供了额外约束，起正则化作用。据此，蒸馏的收益不完全取决于教师的绝对精度，但更强的教师一般更有利。推理时只使用学生，11.2 M 参数，约为教师的 47%，与普通 ResNet18 的部署开销相同。

α 取值过大时损失退化为普通交叉熵，过小时易受教师错误影响；本实验采用的 0.7 与 0.5 均较为稳定。T 在 2 到 8 之间差别不大，$T = 4$ 时软标签的信息量与锐度较为均衡。

7　任务 6：交通标志数据集分类与调参

7.1　完成过程

数据集共 10 类，训练 6024 张、测试 324 张，原始分辨率 224×224，类别分布不均衡：M4 有 3206 张，P10_50 只有 95 张，测试集里最少的类只有 6 张（图 6 左）。

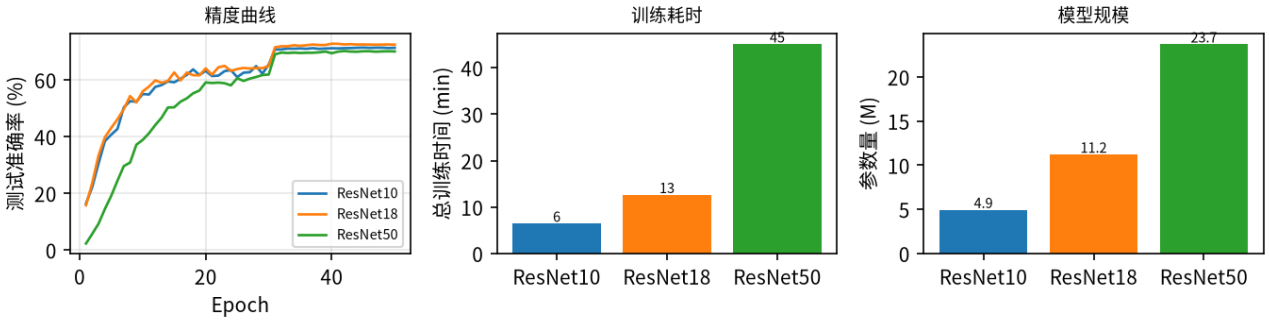


图 4　ResNet10/18/50 的精度曲线、训练耗时与参数量对比

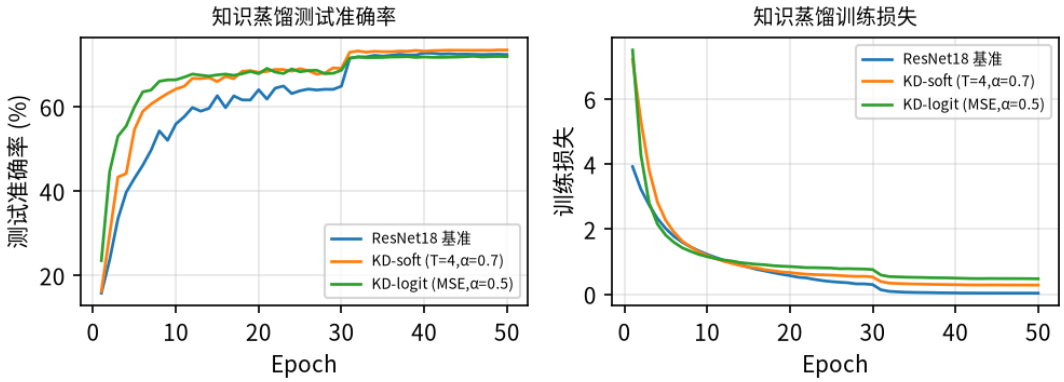


图 5　两种蒸馏损失对学生 ResNet18 的精度与收敛影响

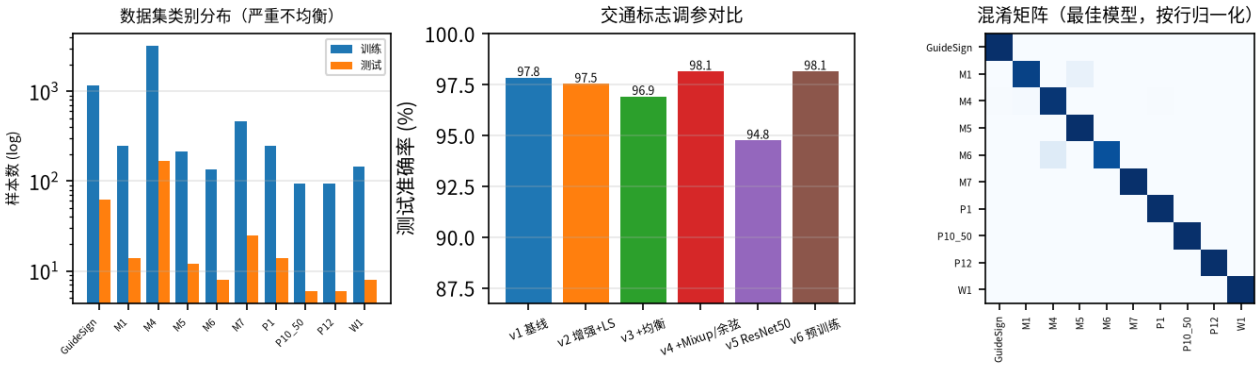


图 6　交通标志数据集分布、六种方案精度对比与最佳模型混淆矩阵

表 7　交通标志数据集上的 6 组调参方案

方案	数据增强	标签平滑	采样	epoch	最佳精度 (%)	耗时 (min)
v1 基线	Resize 128+CE	—	shuffle	50	97.84	21.6
v2 增强 +LS	Random ResizedCrop +Color Jitter +Rotation	0.1	shuffle	50	97.53	25.8
v3 + 均衡采样	同 v2	0.1	WRS	50	96.91	24.3
v4 +Mixup+ 余弦	同 v2 + Mixup(α=0.2)	0.1	WRS	80	98.15	36.2
v5 ResNet50(96)	同 v4	0.1	WRS	40	94.75	31.0
v6 预训练微调	同 v3	0.1	WRS	40	**98.15**	2.0

注：CE 为交叉熵损失，LS 为标签平滑 0.1，WRS 为 WeightedRandomSampler 均衡采样。

原来的接口是按 CIFAR 写的，这里重写了 Dataset。它遍历 train 与 test 下以类别命名的目录，建立类别到索引的映射，读图后按统一的尺寸和归一化参数变换，返回张量与标签；训练集与测试集走两条不同的变换流程，测试集只做缩放。数据加载部分在标准 DataLoader 之外加了自定义采样器：训练集可以选随机打乱，也可以按类别频率加权，权重取类样本数的倒数，batch 大小、worker 数与锁页内存都按本机设置；测试集按顺序加载，保证评估可复现。归一化用的均值与标准差由训练集统计得到，存在结果目录里，均值约为 $[0.30, 0.39, 0.60]$。训练增强包括随机缩放裁剪（0.7∼1.0）、颜色抖动与 $\pm 10°$ 旋转；交通标志水平翻转后会左右颠倒，因此未采用该增强。

调参按 6 组逐级叠加：v1 是基线，只做 Resize 128 和随机打乱，SGD lr=0.05 加 step 衰减；v2 加强增强并加入标签平滑 0.1；v3 在 v2 基础上加类别均衡采样；v4 在 v3 基础上去掉 step 换成余弦退火，再加 Mixup(α=0.2)，训练 80 epoch；v5 换成 ResNet50，8 GB 显存不足以使用原分辨率，改为 96×96、batch=16、lr=0.03，训练 40 epoch；v6 改用 ImageNet 预训练的 ResNet18，lr=0.005，微调 40 epoch，采样方式同 v3。各组精度与耗时见表 7。

7.2 结果分析

v1 的 97.84% 说明在这个数据集上，ResNet18 直接监督训练即可获得较高的精度：类别之间区别明显，多数类的样本也充足。

v2 为 97.53%，与 v1 只差一张测试图，总精度上看不出优势，但各类召回更均匀：宏平均召回由 94.58% 升到 95.72%，M1 由 71.4% 升到 78.6%，M6 由 75.0% 升到 87.5%。也就是说，增强与标签平滑针对的是弱类，并没有去提高总体均值。

v3 的整体精度为 96.91%，比 v2 低 0.62 点，宏平均 96.80%，比 v2 高 1.08 点。M1 与 P1 继续上升，但占测试集 52% 的 M4 略有下降，总数被多数类拉着走低。这一组的结果正好说明，只报总体精度会掩盖少数类上的变化。

v4 达到 98.15%，是六组里从零训练的最高精度。与 v3 相比，它在 Mixup 之外把 step 换成了余弦退火，epoch 增加到 80，决策边界因此更平滑。v5 为 94.75%，比 v4 低 3.40 点，即使把分辨率降到 96×96，单 epoch 的耗时与 v4 相差也不大。本实验的训练集只有 6024 张，ResNet50 的容量用不满，加深网络没有收益。

v6 同为 98.15%，耗时 2.0 min，约为 v4 的十八分之一。它和 v4 的正确数都是 318/324，M1、M4、M6 的召回也相同，均为 92.9%、97.6%、87.5%，区别只在于错的是哪几张图；宏平均为 97.80%。在训练样本有限的情况下，直接用 ImageNet 预训练权重比从零训练更省时间。

需要补充的是，测试集只有 324 张，错一张就是 0.31 点，P10_50 只有 6 张，错一张即 16.7 点。因此各组之间 1 点以内的差异不足以说明方法优劣，判断时还应结合宏平均召回和混淆矩阵。